

《Queues under Stochastic Priority Switching》复现报告

Stochastic Operations Research 复现项目

2026年6月

摘要

本报告基于当前仓库中的完整实验输出，对 Palmer 等人的随机优先级切换队列模型复现工作进行复核。复核方式不是只检查图像是否相似，而是将原文中的关键主张、原始 notebook 参数、当前复现实验 CSV 指标三者逐项对齐。总体结论是：复现工程链路已经基本完成，主要脚本均能产生可审计的 CSV 指标表和 PNG 图；有限截断 Markov 链近似、原始 notebook 参数下的稳定性实验、sojourn-time 二阶矩公式复核，以及部分 H 矩阵热图具有较好的复现效果。但是，当前结果不能简单写成“完全复现成功”：Figure 5 中论文候选点 $(\theta_{12}, \theta_{21}) = (3, 1)$ 没有在当前仿真中同时成为 Wasserstein 与 MAPE 的最优点；论文文本参数下的稳定性 ADF 检验未能判定 stable-like 轨迹平稳；原文 Effect-of- Θ 的 Scenario A 在当前实现中出现 $Q(16)$ 超过 0.012 的情况。新增的综合校准指标适合作为扩展实验中的探索性筛选工具，但不应替代论文原始指标。

目录

1	复现目标与总体判断	3
2	代码架构与结果目录	4
2.1	复现代码结构	4
2.2	结果目录	5
3	参数口径：论文文本 vs 原始 notebook	6
4	逐项复现结果	6
4.1	Figure 5: overtaking 分布拟合	6
4.2	稳定性实验与 ADF 检验	8
4.3	有限边界 Markov 链近似	8
4.4	H 矩阵影响实验	9
4.5	Markov chain vs simulation 验证	10
4.6	Sojourn-time variance 与二阶矩	11
5	扩展实验：综合校准指标是否合理	12
5.1	这个综合指标有什么用	12
5.2	为什么不应替代论文原始做法	13

目录	2
6 主要问题与修正建议	13
6.1 已经完成或已经纳入当前报告的修正	13
6.2 仍需谨慎处理的问题	13
7 最终结论	14
A 本轮实验命令与输出	14

1 复现目标与总体判断

本复现工作的目标不是只生成相似图片，而是确认以下三个层面是否成立：

1. **模型与代码链路是否可运行：** 能否从原始代码、原始数据和论文参数出发，重新生成主要实验结果。
2. **数值结论是否复现：** 论文中关于 overtaking 分布、稳定性、有限边界 Markov 近似、切换率矩阵 H 影响等结论是否在当前实现中得到支持。
3. **扩展是否合理：** 新增的 finer-grid calibration、Markov-vs-simulation 检查、sojourn-time variance 可视化是否与原模型逻辑一致，是否会混淆复现口径。

当前结论可以概括为“**工程复现完成，数值复现混合成功**”。其中，Bounded Markov approximation 是最稳定、证据最强的部分；原始 notebook 参数下的稳定性实验也能复现 stable/unstable 的 ADF 区分。但 Figure 5、论文文本参数下的稳定性、Scenario A 的边界量存在明显 caveat。因此，在最终汇报中建议使用“部分复现成功，并发现若干参数与随机性敏感点”的表述，而不是“完全复现论文全部数值结论”。

为了避免把扩展结果和原文结论混在一起，本报告采用“原文主张-当前证据-判断”的核对口径。核心对应关系如下：

表 1: 原文主张与当前复现证据的对应关系

项目	原文或原始代码口径	当前实验结果	判断
Figure 5 overtaking fitting	原文在 $\{1, 2, 3\} \times \{0, 1, 2\}$ 粗网格中报告 (3, 1) 同时给出较好的 overtaking 分布拟合和等待时间 MAPE。	当前 CSV 中最小 Wasserstein 为 (1, 1), 最小 MAPE 为 (2, 2); (3, 1) 的 Wasserstein 接近最优, 但 MAPE 明显更差。	部分复现; 流程成立, 具体最优点未完全一致。
稳定性 ADF 检验	原文使用 ADF 检验区分达到稳态和未达到稳态的队列长度轨迹; 原始 notebook 与论文文本参数存在 θ_{12} 差异。	原始 notebook 口径下 stable-like $p = 0.00385$, unstable-like $p = 0.8639$; 论文文本口径下 stable-like $p = 0.1562$ 。	notebook 口径复现成功; 论文文本口径证据不足。
Bounded Markov approximation	原文提出随 bound 增大, 有限边界 Markov 链的 L 与 W 应接近长时仿真, 边界量 $Q(b)$ 、 $P(b)$ 应下降。	$b = 22$ 时两套参数的 $Q(b)$ 、 $P(b)$ 均降至 10^{-4} 以下, L 、 W 曲线收敛。	强复现。
Effect of Θ	原文定义 Scenario A/B, 并声称 $h_{12}, h_{21} \in [0, 3]$ 、步长 0.2、bound 16 下 $Q(16), P(16) < 0.012$ 。	当前实现额外加入 equal-rate 场景; 原文 Scenario A 对应当前 A, 原文 Scenario B 对应当前 C。当前 A 的 $\max Q(16) = 0.0822$, 超过阈值; C 达标。	定性趋势可复现, 边界充分性不能无保留复现。
Sojourn-time variance	原文已给出 sojourn time 方差的吸收链二阶矩公式, 并在 case study 中强调方差对优先级切换和服务率敏感。	当前实现复核二阶矩公式, 并生成 convergence 与 heatmap; 数值与 bounded Markov 的 W 、 L 结果一致。	公式与计算路径复现成功; heatmap 属于更系统的展示扩展。

2 代码架构与结果目录

2.1 复现代码结构

复现层位于 `reproduction/`, 没有直接改写原始模型库, 而是以包装脚本的方式调用 `original/src` 中的原始模型函数。主要模块如下:

模块	作用
<code>reproduction/utils.py</code>	统一处理路径、原始手术等待数据、class-switching rate 的零值语义、Ciw 仿真、overtaking 指标。
<code>reproduction/reproduce_figure5.py</code>	复现论文 Figure 5 风格的 overtaking 分布比较，输出 Wasserstein distance 和等待时间 MAPE。
<code>reproduction/reproduce_stability.py</code>	对 stable-like 与 unstable-like 轨迹做 ADF 检验，用于复核稳定性现象。
<code>reproduction/reproduce_bounded_markov.py</code>	计算有限边界 Markov 链下的 L 、 W 、 $Q(b)$ 、 $P(b)$ 随 bound 的变化。
<code>reproduction/reproduce_effect_of_H.py</code>	在 $h_{12} \times h_{21}$ 网格上计算 L_k 、 W_k 、sojourn-time variance U 与边界量。
<code>reproduction/reproduce_mc_vs_sim.py</code>	比较 bounded Markov chain 与离散事件仿真的状态分布和 sojourn-time 均值。
<code>reproduction/reproduce_sojourn_variance.py</code>	复核吸收 Markov 链二阶矩公式，并生成 variance convergence 与 heatmap。
<code>reproduction/extension_calibrate_H.py</code>	扩展实验：使用更细的 H 网格和综合校准损失探索拟合面。
<code>reproduction/run_parameter_variants.py</code>	针对论文文本和原始 notebook 参数不一致处分别运行，避免混用口径。

2.2 结果目录

本轮完整实验结果主要位于：

- `../results/parameter_variants/common/`：无明显论文文本/原 notebook 参数冲突的共同实验，包括 Figure 5 和 effect-of- H 。
- `../results/parameter_variants/paper_text/`：采用论文文本参数的 bounded Markov、stability、MC-vs-sim、variance 实验。
- `../results/parameter_variants/original_notebook/`：采用原始 notebook 参数的对应实验。
- `../results/extension_calibration/`：扩展校准实验。

早期输出已按实验类型归类至 `../results/` 的子目录（`figure5/`、`effect_of_H/`、`bounded_markov/`、`mc_vs_sim/`、`sojourn_variance/`）中。这些文件可能来自修正之前的版本，最终分析应优先采用 `../results/parameter_variants/` 下的新输出。

3 参数口径：论文文本 vs 原始 notebook

本次复现中一个关键处理是将论文文本参数和原始 notebook 参数分开运行。这样做是合理且必要的，因为部分实验的参数来源存在不一致：

表 3: 需要区分的参数口径

实验	论文文本口径	原始 notebook 口径	影响
稳定性实验	$\theta_{12} = 3, \theta_{21} = 1$	$\theta_{12} = 2, \theta_{21} = 1$	ADF 检验结论不同；notebook 口径能复现 stable/unstable 区分。
Bounded Markov、 MC-vs-sim、variance	$\mu_2 = 2.5$	$\mu_2 = 1.6666666667$	两者均收敛，但 L 、 W 的数值水平不同。
Figure 5 与 effect-of- H	共同运行	共同运行	当前脚本中没有作为参数变体拆分。

因此，最终报告中建议同时呈现两版：论文文本版用于对照论文叙述，原始 notebook 版用于判断作者代码路径能否复现。若只采用其中一版，容易把参数差异误解为代码错误或实验失败。

4 逐项复现结果

4.1 Figure 5: overtaking 分布拟合

Figure 5 对应原文 surgical endoscopy case study 中的 overtaking fitting。原文先用真实等待列表构造 observed overtaking distribution，再用 Ciw 仿真在不同 θ_{12}, θ_{21} 下生成 modeled distribution，并用 Wasserstein distance 与 waiting-time MAPE 同时评价拟合质量。当前复现实验沿用这一思路：使用 `original/src/motivating_data/SurgeryTreatment.csv` 作为 observed target，通过 Ciw 仿真生成 overtaking distribution，并在粗网格

$$\theta_{12} \in \{1, 2, 3\}, \quad \theta_{21} \in \{0, 1, 2\}$$

上比较 Wasserstein distance 与 waiting-time MAPE。注意：这两个指标是论文复现口径，应分别报告；不应在 Figure 5 复现实验中用新增综合指标替代。原文的具体数值主张是：在测试的九个候选点中， $(\theta_{12}, \theta_{21}) = (3, 1)$ 给出最佳拟合，并可作为后续 Markov 链分析的一个候选 Θ 。因此，本节的判断重点不是“能否生成一张相似图”，而是当前 CSV 是否也支持 $(3, 1)$ 同时优于其他候选点。




图 1: Figure 5 风格的 overtaking 分布复现图。

当前 CSV 结果显示:

表 4: Figure 5 当前主要结果

判据	最优或关注点	Wasserstein	MAPE
最小 Wasserstein	(1,1)	3.0381	0.1879
论文候选点	(3,1)	3.0528	0.3663
最小 MAPE	(2,2)	4.2217	0.0946
次低 MAPE 附近	(1,2)	3.1471	0.1128

判断: 部分成功。 当前复现成功运行了论文式比较流程, 也生成了合理的分布图。但是论文候选点 (3,1) 在当前 run 中没有成为最小 Wasserstein 点, 也不是最小 MAPE 点。它的 Wasserstein 与最优点 (1,1) 只相差约 0.015, 说明分布形状上并非完全不合理; 但 MAPE 为 0.3663, 明显高于 (2,2) 的 0.0946。因此, 当前结果支持“模型能产生与 observed overtaking 分布相近的结果”, 但不支持“(3,1) 在本轮仿真中同时是两个指标的最优点”。


可能原因包括: 仿真随机性、trial 数较少、Ciw 版本差异、原始数据处理细节、论文图中是否采用更多重复仿真或平滑处理等。若要加强该结论, 需要增加 trials、固定更多随机种子并报告置信区间或 seed sensitivity。

4.2 稳定性实验与 ADF 检验


原文使用 Augmented Dickey–Fuller (ADF) test 检查队列长度轨迹是否呈现 stationarity，并用它说明某些系统会达到稳态、某些系统则表现为持续增长。当前稳定性实验对应这个检查逻辑：对 stable-like 与 unstable-like 两类队列长度轨迹做 ADF 检验，并同时区分论文文本参数与原始 notebook 参数。

表 5: 稳定性实验 ADF 结果

参数口径	stable-like ADF p	stable-like 末端队长	unstable-like ADF p	unstable-like 末端队长
论文文本	0.1562	10	0.8558	241
原始 notebook	0.00385	0	0.8639	144



(a) 论文文本参数



(b) 原始 notebook 参数

图 2: 稳定性复现的两种参数口径。

判断：部分成功。 原始 notebook 参数下，stable-like 的 ADF $p = 0.00385 < 0.05$ ，unstable-like 的 $p = 0.8639$ ，符合“一个平稳、一个非平稳”的预期。论文文本参数下，unstable-like 仍然明显非平稳，但 stable-like 的 ADF $p = 0.1562$ ，不能拒绝单位根；这意味着按严格 ADF 口径，论文文本版没有完全复现。


因此，汇报时建议写为：稳定性现象在原始 notebook 口径下复现，在论文文本口径下视觉上不爆炸但统计检验不充分。这里的差异不应简单归因于“代码失败”，因为参数口径本身不同；但也不应把 notebook 口径的成功直接转写成论文文本口径的成功。

4.3 有限边界 Markov 链近似


原文的 bounded approximation 用有限状态空间近似不可直接求解的无界 Markov 链，并给出两个边界诊断量： $Q(b)$ 衡量稳态分布落在边界上的相对概率， $P(b)$ 衡量到达顾客在吸收链中经历边界的概率。理论叙述是：若系统本身稳定，则随着 bound b 增大，边界影响应逐渐变小，有限边界下的平均系统人数 L 与平均 sojourn time W 应接近无界系统或长时仿真结果。当前 Bounded Markov 实验正是计算不同截断 bound 下的 L 、 W 、 $Q(b)$ 、 $P(b)$ 。两种参数口径在 $b = 22$ 时结果为：

表 6: Bounded Markov 在 $b = 22$ 的结果

参数口径	μ_2	L	W	$Q(b)$	$P(b)$
论文文本	2.5	1.6197	1.6199	5.88×10^{-5}	2.39×10^{-5}
原始 notebook	1.6667	1.9158	1.9161	7.61×10^{-5}	3.10×10^{-5}



(a) 论文文本参数



(b) 原始 notebook 参数

图 3: Bounded Markov approximation 随截断边界的变化。

判断：成功。 这是当前复现中最可靠的一部分。两套参数在较大 bound 下均表现出收敛，边界量下降到 10^{-4} 以下，说明有限截断对稳态均值的影响已经较小。尤其是 $b = 22$ 时，论文文本口径下 $L = 1.6197$ 、 $W = 1.6199$ ，原始 notebook 口径下 $L = 1.9158$ 、 $W = 1.9161$ ，两者的差异主要来自 μ_2 口径不同，而不是收敛行为相互矛盾。

需要注意的是，低 bound 下当前代码输出的 $P(b)$ 在个别点可能超过 1。按原文定义， $\mathcal{P}(b)$ 应是 arrival customer experiencing the boundary 的概率；因此该现象更像是低边界下实现细节、归一化方式或适用条件需要进一步核对，而不是一个可以直接解释为概率的结果。最终报告中应强调较大 bound 下边界量已经很小，不建议使用低 bound 的 $P(b) > 1$ 作为实质性结论。

4.4 H 矩阵影响实验

原文 Effect of Θ 小节定义了两个 service-rate scenario: Scenario A 中高优先级顾客服务率较慢，Scenario B 中高优先级顾客服务率较快；随后在 $h_{12}, h_{21} \in [0, 3]$ 、步长 0.2、bound 16 的网格上比较 L_k 与 sojourn-time 结果，并声称这些点的 $Q(16), P(16) < 0.012$ 。当前脚本为了更完整地观察服务率关系，额外加入了 equal-rate 场景，因此命名为 A/B/C: 当前 A 对应原文 Scenario A，当前 C 对应原文 Scenario B，当前 B_equal 是新增的中间对照。实验在 16×16 网格上计算 L_k 、 W_k 、variance U 、 $Q(16)$ 、 $P(16)$ 。三种 service-rate scenario 的边界结果如下：

表 7: Effect-of- H 边界量检查

Scenario	$\max Q(16)$	$\max P(16)$	$U_{\min}$	$U_{\max}$	判断
A: prioritized class slower (原文 A)	0.0822	0.0120	1.704	7.927	P 基本达标, 但 Q 明显超过 0.012, 181 个网格点超过阈值。
B: equal rates (新增对照)	0.00753	0.00114	1.022	1.966	Q 与 P 均达标。
C: prioritized class faster (原文 B)	0.0102	0.00152	0.521	2.257	Q 与 P 均达标。

判断: 部分成功。 当前结果支持原文的定性结论: θ_{12} 与 θ_{21} 的相对大小会改变各类顾客数量、sojourn time 和二阶矩, 服务率关系也会改变这种影响的方向。但是, 边界充分性不能无保留复现。原文 Scenario B 对应的当前 C 达标, 新增 equal-rate 场景也达标; 原文 Scenario A 对应的当前 A 则出现 $\max Q(16) = 0.0822$, 明显高于 0.012。换言之, 当前复现实验不能直接支持“所有原文网格点在 bound 16 下均满足 $Q(16), P(16) < 0.012$ ”。

此外, 先前生成的 effect-of- H 图标题存在一个小的展示 bug: 标题中 scenario 字母来自文件名最后一个字符。代码已经改成取 scenario 名称的第一个字段, 例如 A/B/C。这个问题不影响 CSV 数值, 但影响图片展示质量。

4.5 Markov chain vs simulation 验证

MC-vs-sim 实验不是原文 Figure 5 或 Effect-of- Θ 的直接替代, 而是对 bounded Markov approximation 的额外 sanity check: 若有限边界 Markov 链和离散事件仿真描述的是同一模型, 则随着 bound 增大, 状态分布差异应下降, sojourn-time 均值也应处在可解释的误差范围内。当前结果为:

表 8: MC-vs-sim 误差范围

参数口径	W 相对误差范围	状态分布 Wasserstein 范围
论文文本	5.93%–7.68%	0.251–0.395
原始 notebook	4.43%–6.29%	0.104–0.308




图 4: 论文文本参数下的 Markov chain vs simulation 比较。

判断: 趋势合理, 但证据强度有限。状态分布误差整体随 bound 增大而下降, 说明 Markov 近似方向正确; 但 sojourn-time 均值误差仍在 4%-8% 左右, 并且并非严格单调。考虑到当前仿真时间为 5000, 而论文或原始 notebook 中可能使用更长运行时间, 该实验更适合作为 sanity check, 不适合作为最终严格验证。

4.6 Sojourn-time variance 与二阶矩

原文在 sojourn-time Markov chain formulation 中不仅给出 mean sojourn time, 也给出 variance in sojourn times 的二阶矩计算方式; 后文 case study 还强调方差对 stochastic priority switching 和服务率设置非常敏感。当前 sojourn-time variance 实验不是凭空新增一个指标, 而是复核原文吸收 Markov 链矩公式, 并把二阶矩结果系统地做成 convergence 与 heatmap。当前结果包括:

表 9: Sojourn-time variance 关键结果

参数口径	bound	W	$\text{Var}(W)$	L
论文文本	16	1.6216	5.6492	1.6182
原始 notebook	16	1.9184	7.2313	1.9138

论文文本参数的 heatmap 中, $\text{Var}(W)$ 最小点为 $(h_{12}, h_{21}) = (3, 0)$, $\text{Var}(W) = 2.0742$; 最大点为 $(3, 3)$, $\text{Var}(W) = 6.1467$ 。原始 notebook 参数下, 最小点为 $(0, 3)$, $\text{Var}(W) = 3.9006$; 最大点为 $(0.6, 0.2)$, $\text{Var}(W) = 7.4228$ 。




图 5: 论文文本参数下的 sojourn-time variance 结果。

判断: 成功。该部分与原论文的吸收链矩公式一致, 数值结果也与 bounded Markov 的 W 、

L 结果相互吻合。需要注意的是, sojourn-time variance 本身并不是完全脱离论文的新指标; 论文已有二阶矩公式。当前工作的增量主要体现在两点: 一是用 convergence 曲线检查不同 bound 下二阶矩是否稳定, 二是用 heatmap 展示 H 网格上 variance 的敏感性。这种写法既能体现扩展价值, 又不会把原文已有公式误写成全新的方法。

5 扩展实验：综合校准指标是否合理

扩展脚本 `reproduction/extension_calibrate_H.py` 使用更细的 11×7 网格探索 θ_{12}, θ_{21} , 并定义

$$\text{calibration_loss} = \alpha \cdot \text{Wasserstein} + \beta \cdot \text{MAPE}, \quad \alpha = \beta = 1.$$

当前结果如下:

表 10: 扩展校准实验关键点

判据	点 (h_{12}, h_{21})	Wasserstein	MAPE
最小综合 loss	(3, 2)	2.6568	0.1792
最小 Wasserstein	(1, 2)	2.5763	0.2851
最小 MAPE	(3.5, 2)	3.3684	0.1084
论文点	(3, 1)	3.9768	0.5179




图 6: 扩展校准综合损失热图。

5.1 这个综合指标有什么用

综合指标的用途是**扩展校准**, 即在更细的参数网格中快速筛选同时兼顾 distribution shape 和 waiting-time scale 的候选点。Wasserstein distance 主要看 overtaking 分布形状, MAPE 主要看 bumped-up / bumped-down 两类等待时间均值是否接近。把二者线性相加, 可以给出一个简单的排序, 从而发现“单看一个指标好、另一个指标很差”的点。例如当前扩展中, (1, 2) 的 Wasserstein 最低但 MAPE 较高, (3.5, 2) 的 MAPE 最低但 Wasserstein 较高, 而 (3, 2) 在两者之间取得折中, 因此成为综合 loss 的最小点。

5.2 为什么不应替代论文原始做法

综合指标不应替代论文复现指标，原因有三点：

1. 不是论文定义的指标。论文 Figure 5 对比的是分布形状和等待时间表现，未定义该线性组合 loss。
2. 量纲和尺度未归一化。Wasserstein 和 MAPE 的数值尺度不同， $\alpha = \beta = 1$ 是人为选择；当前排序可能由 Wasserstein 主导。
3. trial 数较少。当前扩展只用 3 个 trials，适合发现趋势，但不足以作为最终最优参数结论。
4. 它回答的问题不同。原文 Figure 5 问的是九个候选参数在原始指标下的拟合表现；扩展实验问的是更细网格上是否存在折中更好的候选点。后者可以启发 sensitivity analysis，但不能反向改写原文 Figure 5 的复现判据。

因此，最合理的写法是：复现部分仍按论文原始指标分别报告；扩展部分另做综合 loss，作为 sensitivity analysis 和参数筛选工具。这样既保留复现口径的严谨性，也能说明新增指标的研究价值。

6 主要问题与修正建议

6.1 已经完成或已经纳入当前报告的修正

- 零切换率语义已修正：Ciw 仿真中禁用切换使用 None，Markov 链计算中使用数值 0.0。
- Figure 5 复现不再使用综合 loss 排序，而是分别报告 Wasserstein 与 MAPE。
- 参数变体脚本已支持论文文本和原始 notebook 两套口径。
- Bounded Markov 默认 bound 和 service-rate 参数已显式化，便于区分参数来源。
- Effect-of- H 绘图标题已修正为 A/B/C scenario 标识。

6.2 仍需谨慎处理的问题

- Figure 5 的 (3,1) 结论未完全复现，建议增加 trials、种子重复和置信区间。
- 论文文本稳定性 ADF 检验未通过，建议增加仿真时长、重复轨迹，并比较不同 ADF lag 设定。
- 原文 Scenario A 对应的当前 A 的 $Q(16)$ 超阈值，不能直接声称该 bound 对所有原文 H 网格充分。
- MC-vs-sim 的仿真时间较短，当前只能作为 sanity check。
- 低 bound 下的 $P(b) > 1$ 需要进一步核对原始函数含义，避免误称为概率。

7 最终结论

从当前结果看，复现工作已经达到“可提交并可解释”的程度，但结论必须诚实分层：

- **强复现：** Bounded Markov approximation；原始 notebook 参数下的 stability split；sojourn-time 二阶矩计算。
- **部分复现：** Figure 5 overtaking fitting；论文文本参数下 stability；Effect-of- Θ 中原文 Scenario A 的边界充分性。
- **合理扩展：** fine-grid calibration 和综合 loss；MC-vs-sim validation；equal-rate H 场景；variance heatmap。它们有解释价值，但需要清楚标注为扩展或诊断，不应作为论文原结论的直接替代。

建议最终汇报采用如下表述：本项目成功搭建了完整复现实验框架，并复现了论文中 Markov 链近似和部分稳定性/切换率影响结论；同时，复现实验揭示出论文文本、原始 notebook 与有限仿真设置之间存在若干敏感差异，尤其是 Figure 5 参数排序、稳定性 ADF 检验和 Scenario A 边界量。因此，本复现的贡献不仅是生成图表，也包括识别并解释这些不一致点。

A 本轮实验命令与输出

本轮完整结果对应的核心命令为：

```
python -m reproduction.run_parameter_variants --variant both --include-common
python -m reproduction.extension_calibrate_H
```

主要输出文件包括：

- `../results/parameter_variants/common/figure5_metrics.csv`
- `../results/parameter_variants/common/effect_of_H_A_prioritized_slower.csv`
- `../results/parameter_variants/common/effect_of_H_B_equal.csv`
- `../results/parameter_variants/common/effect_of_H_C_prioritized_faster.csv`
- `../results/parameter_variants/paper_text/stability_metrics.csv`
- `../results/parameter_variants/original_notebook/stability_metrics.csv`
- `../results/parameter_variants/paper_text/bounded_markov_metrics.csv`
- `../results/parameter_variants/original_notebook/bounded_markov_metrics.csv`
- `../results/extension_calibration/extension_calibration_metrics.csv`